

Projet de Machine Learning

Gestion des ventes et prévision des sorties de stock

Contexte

Une boutique dispose d'un système informatique de gestion de stock dont les données sont enregistrées dans un fichier Excel composé des feuilles suivantes :

- **Feuille 1 : Liste des marchandises**

- Référence produit
- Désignation
- Catégorie
- Prix unitaire

- **Feuille 2 : Entrées**

- Date d'entrée
- Référence produit
- Quantité entrée

- **Feuille 3 : Sorties**

- Date de sortie
- Référence produit
- Quantité vendue

- **Feuille 4 : Inventaire**

- Référence produit
- Stock actuel

L'objectif est d'utiliser les techniques de Machine Learning afin d'analyser les données commerciales et de prédire les ventes futures.

Travail demandé

Partie 1 : Préparation des données

1. Charger les différentes feuilles du fichier Excel avec Python.
2. Fusionner les données nécessaires afin de constituer une base d'apprentissage.
3. Identifier les variables explicatives et la variable cible.
4. Traiter les éventuelles valeurs manquantes.
5. Appliquer une technique de normalisation adaptée.

Partie 2 : Analyse exploratoire

1. Produire des statistiques descriptives.
2. Identifier les produits les plus vendus.
3. Visualiser la répartition des ventes.
4. Étudier les relations entre les variables disponibles.

Partie 3 : Apprentissage supervisé

On souhaite prédire la quantité qui sera vendue pour un produit.

La variable cible est :

$$Y = \text{Quantité vendue}$$

Les variables explicatives pourront être choisies parmi :

- Prix unitaire
 - Quantité entrée
 - Stock disponible
 - Catégorie du produit
 - Toute autre variable pertinente construite à partir des données
1. Construire un modèle de **régression linéaire**.
 2. Évaluer ses performances.
 3. Construire un modèle utilisant l'algorithme **KNN Regressor**.
 4. Tester plusieurs valeurs de k .
 5. Comparer les résultats obtenus.

Partie 4 : Choix du meilleur modèle

1. Comparer les performances des modèles développés.
2. Utiliser au moins un indicateur parmi :
 - RMSE
 - MAE
 - R^2
3. Identifier le modèle le plus performant.
4. Justifier votre choix.

Questions de réflexion

1. Pourquoi la normalisation est-elle particulièrement importante pour KNN ?
2. Quels sont les avantages et les limites de la régression linéaire ?
3. Dans quel cas un modèle KNN peut-il être préférable ?
4. Comment pourrait-on améliorer davantage les prédictions ?

Livrables

Chaque groupe devra fournir :

- Le notebook Python commenté ;
- Les graphiques produits ;
- Un rapport de 3 à 5 pages présentant :
 - la méthodologie,
 - les résultats obtenus,
 - la comparaison des modèles,
 - les conclusions.