

Rapport de Synthèse

Projet de Machine Learning — Gestion des ventes et prévision des sorties de stock

Filière : Informatique | Module : Machine Learning
Année universitaire 2024-2025

Resume executif

Ce rapport presente la demarche complete d'un projet de Machine Learning applique a la gestion des ventes d'une boutique. A partir de donnees multi-tables (marchandises, entrees, sorties, inventaire), nous avons construit une base d'apprentissage de 900 observations, realise une analyse exploratoire approfondie, puis compare deux modeles de regression supervisee : la **Regression Lineaire** et le **KNN Regressor**. Les resultats revelent une relation faiblement lineaire entre les features disponibles et les quantites vendues (R^2 max = 0.016), ce qui constitue en soi une conclusion importante pour orienter les travaux futurs.

1. Methodologie et preparation des donnees

1.1 Contexte et sources de donnees

La boutique dispose d'un systeme de gestion dont les donnees sont reparties en quatre feuilles Excel : **Liste des marchandises** (500 produits, catalogue de reference), **Entrees** (800 mouvements d'approvisionnement), **Sorties** (900 transactions de vente, table centrale du projet), et **Inventaire** (500 lignes de stock final par produit). La periode couverte s'etend du 01/01/2025 au 20/03/2026.

1.2 Nettoyage des donnees (Notebook 01)

Chaque table a ete soumise a un diagnostic systematique (types, valeurs manquantes, doublons, coherence des calculs derives). Les operations de nettoyage appliquees sont :

- Normalisation des noms de colonnes (minuscules, underscores, suppression des apostrophes).
- Conversion des colonnes date de format texte YYYY-MM-DD en type datetime.
- Recalcul et correction de 40 statuts d'inventaire erronees (35 ruptures de stock classees 'stock faible', 5 reclassifications 'stock normal' -> 'stock faible').
- **Correction des stocks negatifs (amelioration v2)** : 35 produits presentaient un stock_final < 0 (jusqu'a -237 unites), anomalie physiquement impossible. Ces valeurs ont ete remplacees par 0 via clip(lower=0) avant export.

Resultat : 4 tables propres exportees dans stock_boutique_nettoye.xlsx, 0 valeur manquante, 0 doublon.

1.3 Strategie de fusion (Notebook 02)

La construction de la base d'apprentissage suit un pipeline de jointures en trois etapes :

- **Etape A** : Jointure gauche Sorties <- Inventaire sur 'reference'. Chaque vente recoit les informations de stock (stock_actuel, seuil_d_alerte).
- **Etape B** : Agregation prealable des Entrees par produit (SUM de quantite GROUP BY reference). Sans cette agregation, chaque vente serait dupliee autant de fois qu'il y a d'entrees pour le produit.
- **Etape C** : Jointure gauche Base <- Entrees agregees. Les valeurs NaN (produits sans entree enregistree) sont imputees a 0.

Base finale : 900 lignes x 9 colonnes. Variable cible Y = quantite_vendue.

1.4 Feature Engineering (Notebook 04 — amelioration v2)

L'EDA ayant revele des correlations toutes inferieures a 0.21, quatre nouvelles variables ont ete construites avant modelisation :

Feature	Formule	Interpretation
ratio_stock_alerte	stock_actuel / (seuil_d_alerte + 1)	< 1 : risque de rupture > 1 : stock confortable
mois	date.dt.month	Saisonnalite mensuelle (1-12)
trimestre	date.dt.quarter	Saisonnalite trimestrielle (1-4)
jour_semaine	date.dt.dayofweek	Effet jour de semaine (0=lun, 6=dim)

Ces features portent le nombre de variables explicatives de 5 a 9 avant encodage.

2. Analyse exploratoire des donnees

2.1 Statistiques descriptives

La base d'apprentissage (900 observations) presente les caracteristiques suivantes :

Variable	Min	Moyenne	Max	Ecart-type	Observations
prix_unitaire (Ar)	60 893	1 218 797	4 231 089	935 030	Amplitude tres large (CV > 75%)
quantite_entree	0	94.5	485	85.7	Queue de distribution a droite
stock_actuel	0*	env. 100	variable	—	*apres clip(lower=0)
seuil_d_alerte	3	14.5	25	6.6	Distribution concentree
quantite_vendue (Y)	1	39.8	80	22.9	Distribution quasi-uniforme

2.2 Variable cible : quantite_vendue

La variable cible presente une distribution remarquablement plate (skewness = 0.066, kurtosis = -1.18). Les quantites vendues se repartissent quasi-uniformement entre 1 et 80 unites, avec une moyenne de 39.8 et une mediane de 38. Le test de Shapiro-Wilk rejette la normalite stricte ($p < 0.001$), mais le Q-Q plot montre des deviations moderees aux queues. Aucun outlier detecte sur la cible : aucune transformation logarithmique requise.

2.3 Analyse des correlations

La matrice de correlation de Pearson revele des associations tres faibles entre les variables brutes et la cible :

Variable	Correlation avec quantite_vendue	Interpretation
stock_actuel	-0.20	Plus le stock est eleve, moins on vend (relation inverse)
seuil_d_alerte	~0.12	Correlation positive faible
quantite_entree	~0.10	Correlation positive faible
prix_unitaire	~0.05	Quasi-nulle
categorie (encode)	variable	Impact visible en analyse categorielle

Ces faibles correlations signalent que les features disponibles n'entretiennent pas de relation purement lineaire avec les quantites vendues. C'est precisement ce constat qui justifie le recours au KNN (modele non-lineaire) et la creation de nouvelles features.

3. Modelisation et resultats

3.1 Pipeline de preprocessing

Etape	Operation	Detail
1	Correction anomalies	stock_actuel.clip(lower=0)
2	Feature Engineering	ratio_stock_alerte, mois, trimestre, jour_semaine
3	One-Hot Encoding	categorie -> 3 dummies (drop_first=True, ref : Electromenager)
4	Split Train/Test	80% / 20%, random_state=42, shuffle=True

5	StandardScaler	fit sur train uniquement, transform sur train + test
6	Modelisation	Regression Lineaire + KNN (k=1 a 20)

3.2 Modele 1 — Regression Lineaire

La regression lineaire modelise quantite_vendue comme une combinaison lineaire ponderee des features : $Y = B_0 + B_1 \cdot X_1 + \dots + B_n \cdot X_n$. Les coefficients sont appris par minimisation des moindres carres ordinaires (OLS). Le coefficient le plus fort est celui de stock_actuel (-7.36 apres standardisation), coherent avec la correlation negative observee en EDA. Cependant, le $R^2 = 0.008$ sur le jeu de test indique que le modele n'explique que moins de 1% de la variance de la cible.

3.3 Modele 2 — KNN Regressor

Le KNN predit quantite_vendue en calculant la moyenne des k voisins les plus proches dans l'espace des features standardisees (distance euclidienne). Tous les k de 1 a 20 ont ete testes. Le meilleur k = 7 atteint $R^2 = -0.039$, ce qui signifie que le modele est moins performant que la prediction naive (toujours predire la moyenne). Ce resultat s'explique par la malédiction de la dimensionnalite : avec 7+ features dont 3 dummies binaires, la distance euclidienne perd en pertinence.

4. Comparaison des modeles et conclusions

4.1 Tableau comparatif des performances

Modele	MAE	RMSE	R2 test	R2 CV (5-fold)	
Regression Lineaire	18.45	22.04	0.0083	0.0431	Meilleur
KNN (k=7)	18.81	22.56	-0.039	-0.086	Moins bon
KNN (k=3)	~21.7	~25+	-0.38	—	Surapprentissage
KNN (k=15)	~19.5	~23	-0.06	—	Sous-apprentissage

4.2 Identification du meilleur modele

Modele retenu : Regression Lineaire

La regression lineaire obtient la MAE la plus basse (18.45 unites) et le R^2 le plus eleve (0.0083 sur le test, 0.0431 en validation croisee). Meme si ces performances restent modestes en valeur absolue, elles dominent systematiquement le KNN sur toutes les metriques. Le KNN souffre ici de la *malediction de la dimensionnalite* : avec 10 features apres encodage, les distances euclidiennes deviennent peu informatives.

4.3 Analyse critique des resultats

Les deux modeles presentent des performances globalement faibles, ce qui est en soi une conclusion importante du projet. Les causes probables sont les suivantes :

- **Variables manquantes** : la demande est influencee par des facteurs absents du systeme — promotions, comportement client, evenements locaux, meteo.

- **Cible quasi-uniforme** : quantite_vendue varie de 1 a 80 avec une distribution tres plate (kurtosis = -1.18). Il y a peu de signal a capturer.
- **Absence de relation lineaire** : toutes les correlations de Pearson restent inferieures a 0.21, confirmant que les features brutes ne permettent pas de predire les ventes via un modele simple.

5. Reponses aux questions de reflexion

Q1. Pourquoi la normalisation est-elle particulièrement importante pour KNN ?

Le KNN calcule des distances euclidiennes entre observations. Sans normalisation, une variable a grande echelle (prix_unitaire : de 60 000 a 4 200 000 Ar) ecrase complètement les autres (mois : 1-12, dummies : 0-1) dans le calcul de distance. Deux produits a 100 000 Ar de difference sembleraient infiniment plus eloignes que deux produits vendus le meme mois — le modele ignorerait de facto toutes les autres variables. Le StandardScaler (moyenne = 0, ecart-type = 1) remet toutes les features sur un pied d'egalite.

Q2. Quels sont les avantages et les limites de la regression lineaire ?

Avantages : interpretabilite totale (chaque coefficient quantifie l'effet marginal d'une variable), rapidite de calcul, faible variance. Limites : suppose une relation strictement lineaire entre X et Y — hypothese invalidee ici ($R^2 < 0.02$). Ne capte ni les interactions entre variables, ni les effets non-lineaires. Sensible aux outliers et a la multicolinearite.

Q3. Dans quel cas un modele KNN peut-il etre preferable ?

Le KNN est preferable quand : (1) la relation entre X et Y est non-lineaire et complexe, (2) le jeu de donnees est de taille moderee (le KNN a une complexite de prediction $O(n)$), (3) le nombre de features est limite (moins de 10-15) pour eviter la malediction de la dimensionnalite. Il excelle notamment pour des problemes de recommandation ou de segmentation ou les similarites locales ont un sens metier fort.

Q4. Comment pourrait-on ameliorer davantage les predictions ?

Quatre pistes d'amelioration prioritaires : (1) Modeles non-lineaires — Random Forest ou Gradient Boosting (XGBoost/LightGBM) pour capturer les interactions complexes ; (2) Enrichissement des donnees — ajouter des variables de contexte (promotions, evenements locaux, meteo, historique client) ; (3) Reformulation du probleme — predire une classe de volume (faible / moyen / fort) transforme le probleme en classification, plus robuste avec les features disponibles ; (4) Modeles de series temporelles — SARIMA ou Prophet pour exploiter la structure temporelle des ventes.

Conclusion

Ce projet a permis de mettre en oeuvre un pipeline complet de Machine Learning : nettoyage multi-tables, fusion par jointures, analyse exploratoire, feature engineering et comparaison de modeles de regression supervisee. Le modele retenu est la Regression Lineaire ($MAE = 18.45$, $R^2 = 0.008$), qui surpasse systematiquement le KNN malgre des performances absolues modestes.

Les faibles R^2 obtenus ne sont pas un échec méthodologique : ils démontrent que les features disponibles (prix, catégorie, stock, entrées, date) ne permettent pas d'expliquer les variations des quantités vendues par des modèles simples. Ce constat constitue une recommandation opérationnelle claire : la boutique devrait enrichir ses données (historique promotions, fichier client) et envisager des modèles non-linéaires pour améliorer la qualité des prédictions.